

Inteligencia Artificial


Búsqueda adversarial y Árboles de juegos

[Slides adapted from Dan Klein and Pieter Abbeel (ai.berkeley.edu).

Sergey Levine & Stuart Russell University of California, Berkeley]




Búsqueda adversarial y Árboles de juegos




Estado del arte en juegos

- Damas: 1950: Primer sistema automático. 1994: Primer campeón automático: Chinook acabó con el reinado de 40 años de la campeona Marion Tinsley. 2007: ¡Damas resueltas!
- Ajedrez: 1997: Deep Blue derrota al campeón Gary Kasparov en un torneo de 6 partidas. Deep Blue examinó 200M posiciones por segundo, usando una evaluación sofisticada y descubrió métodos para extender varias líneas de investigación hasta 40 capas. Los programas actuales son todavía mejores.
- Go: Los campeones humanos empiezan a ser superados por las máquinas. En go, $b > 300$! Los programas clásicos usan bases de conocimiento de patrones, pero recientes avances usan métodos de expansión Monte Carlo (randomizados)




Estado del arte en juegos

- Damas: 1950: Primer sistema automático. 1994: Primer campeón automático: Chinook acabó con el reinado de 40 años de la campeona Marion Tinsley. 2007: ¡Damas resueltas!
- Ajedrez: 1997: Deep Blue derrota al campeón Gary Kasparov en un torneo de 6 partidas. Deep Blue examinó 200M posiciones por segundo, usando una evaluación sofisticada y descubrió métodos para extender varias líneas de investigación hasta 40 capas. Los programas actuales son todavía mejores.
- Go: 2016: Alpha GO derrota al campeón. Usa Monte Carlo Tree Search, función de evaluación aprendida.
- Pacman



Comportamiento y computación



[Demo: mystery pacman (L6D1)]

Video Demo Mystery Pacman




Juegos Adversariales




Tipos de juegos

- ¡Hay muchas clases de juegos!
- A tener en cuenta:
 - ¿Determinístico o estocástico?
 - ¿Uno, dos o más jugadores?
 - ¿Suma cero?
 - ¿Información perfecta (podemos ver el estado)?
- Queremos algoritmos para calcular una estrategia (política o policy) que recomiende un movimiento desde cada estado




Juegos determinísticos

- Muchas formalizaciones posibles, una es:
 - Estados: S (inicio en s_0)
 - Jugadores: $P=\{1...N\}$ (normalmente a turnos)
 - Acciones: A (puede depender del jugador / estado)
 - Función de transición: $S \times A \rightarrow S$
 - Test de terminación (estado objetivo o final): $S \rightarrow \{t,f\}$
 - Función de utilidad para terminal (Terminal Utilities):
 - ¿qué valor tiene este estado final para un jugador?
 - $S \times P \rightarrow R$
- La solución para un jugador es una política (**policy**): $S \rightarrow A$




Juegos de suma cero



➤ Juegos de suma cero


- Los agentes tienen utilidades opuestas (valores)
- Podemos pensar en un único valor que uno maximiza y el otro minimiza
- Adversarial, competición pura




➤ Juegos Generales

- Los agentes tienen utilidades independientes (valores)
- Cooperación, indiferencia, competición, y más, todo es posible
- Más después

Búsqueda Adversarial



Árboles con un solo Agente




Valor de un estado

Valor de un estado: El mejor resultado (utility) desde ese estado

Estados no terminales:


$$V(s) = \max_{s' \in \text{children}(s)} V(s')$$



Estados terminales:

$$V(s) = \text{conocido}$$

Árboles de estados Adversariales




Valores Minimax

Estados bajo el control del agente:

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

Estados bajo el control del oponente:


$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$



Estados terminales:

$V(s) = \text{conocido}$

Árbol de juegos de Tic-Tac-Toe



Búsqueda Adversarial (Minimax)


➤ Juegos determinísticos, de suma cero:

- Tic-tac-toe, ajedrez, damas
- Un jugador maximiza el resultado
- El otro minimiza el resultado

➤ Búsqueda Minimax:

- Árbol de búsqueda en un espacio de estados
- Los jugadores alternan turnos
- Se calcula el **valor minimax** de cada nodo: el máximo resultado (utility) posible contra un adversario racional (óptimo)

Valores Minimax:
calculados **recursivamente**



Valores terminales:
parte del juego

Implementación de Minimax


```
def max-value(state):
```

```
    initialize v =  $-\infty$ 
```

```
    for each successor of state:
```

```
        v = max(v, min-  
                value(successor))
```

```
    return v
```



```
def min-value(state):
```

```
    initialize v =  $+\infty$ 
```

```
    for each successor of state:
```

```
        v = min(v, max-  
                value(successor))
```

```
    return v
```

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$

El valor v empieza con $-\infty$ y va aumentando

El valor v empieza con $+\infty$ y va disminuyendo

Implementación de Minimax (Dispatch)

```
def value(state):
```

if the state is a terminal state: return the state's utility

if the next agent is MAX: return max-value(state)

if the next agent is MIN: return min-value(state)

```
def max-value(state):
```

initialize $v = -\infty$

for each successor of state:

$v = \max(v,$
 value(successor))

return v

```
def min-value(state):
```


initialize $v = +\infty$

for each successor of state:


$v = \min(v,$
 value(successor))

return v


Ejemplo de Minimax






Árbol de una aplicación del mini-max



Árbol de una aplicación del mini-max



Propiedades de Minimax



Óptimo contra un jugador perfecto. ¿En otro caso?

[Demo: min vs exp (L6D2, L6D3)]

Video Demo Minimax vs. Exp (Minimax)




Video Demo Minimax vs. Exp (Exp)




Eficiencia de Minimax


- ¿Cómo de eficiente es minimax?
 - Igual que (exhaustivo) DFS
 - Tiempo: $O(b^m)$
 - Espacio: $O(b^m)$
- Ejemplo: para ajedrez, $b \sim 35$, $m \sim 100$
 - Una solución exacta es inviable
 - Pero, ¿Tenemos que explorar el árbol entero?



Podado del árbol de juego




Podado de Minimax



Podado Alpha-Beta

- Configuración General (versión MIN)
 - Estamos calculando un valor-MIN en un nodo n
 - Estamos iterando sobre los hijos de n
 - Al estar minimizando, el valor de n irá reduciéndose
 - ¿Dónde se usa el valor de n ? MAX
 - Sea a el mejor valor que MAX puede obtener a lo largo del camino actual desde la raíz
 - Si n es peor que a , MAX lo evitará, por ello podemos evitar el considerar los demás hijos de n (es suficientemente malo para saber que no se hará esa jugada).
- La versión MAX es simétrica



Implementación de Alfa-Beta


α : la mejor opción de MAX's en el camino a la raíz
 β : la mejor opción de MIN's en el camino a la raíz

```
def max-value(state,  $\alpha$ ,  $\beta$ ):  
    initialize  $v = -\infty$   
    for each successor of state:  
         $v = \max(v, \text{value}(\text{successor}, \alpha, \beta))$   
        if  $v \geq \beta$  return  $v$   
         $\alpha = \max(\alpha, v)$   
    return  $v$ 
```


```
def min-value(state,  $\alpha$ ,  $\beta$ ):  
    initialize  $v = +\infty$   
    for each successor of state:  
         $v = \min(v, \text{value}(\text{successor}, \alpha, \beta))$   
        if  $v \leq \alpha$  return  $v$   
         $\beta = \min(\beta, v)$   
    return  $v$ 
```

Propiedades de podado Alfa-Beta


- ¡El podado no tiene efecto sobre el valor minimax calculado para la raíz!
- Los valores de nodos intermedios pueden ser incorrectos
 - Importante: los hijos de la raíz pueden tener un valor incorrecto
 - Por ello, una versión simple no permitirá elegir una acción (hijos de la raíz)
- Una buena ordenación de los hijos mejora la efectividad del podado
- Con una “ordenación perfecta”:
 - La complejidad en tiempo se reduce a $O(b^{m/2})$
 - ¡Dobla la profundidad que se puede explorar!



Alpha-Beta Quiz




Alpha-Beta Quiz 2



Alpha-Beta Demo


- Demo: minimax game search algorithm with alpha-beta pruning (using html5, canvas, javascript, css)
- <http://homepage.ufp.pt/jtorres/ensino/ia/alfabeta.html>

Recursos limitados



Recursos limitados

- Problema: en juegos reales, ¿no podemos buscar hasta las hojas!
- Solución: búsqueda limitada en profundidad (Depth-limited search)
 - Buscar solo una profundidad limitada del árbol
 - Reemplazar las utilidades terminales con una función de evaluación para posiciones no terminales
- Ejemplo:
 - Suponer que tenemos 100 segundos, y podemos explorar 10K nodos / seg
 - Podemos explorar 1M nodos por movimiento
 - α - β llega a profundidad 8 – programa de ajedrez decente
- La garantía de juego óptimo se desvanece
- Usar iterative deepening para tener un anytime algorithm (lo mejor posible dado un tiempo limitado)




Vídeo of Demo Thrashing ($d=2$)



[Demo: thrashing $d=2$, thrashing $d=2$ (fixed evaluation function) (L6D6)]

Por qué Pacman desfallece



- ¡Peligro de agentes que replanifican!
- Pacman sabe que su puntuación aumentará yendo en las 2 direcciones comiendo un punto (west, east). P. ej.: función de evaluación: 10 por cada punto comido
 - Pero Pacman sabe que su puntuación también subirá si hace (east, west)
 - Después de comer el punto, no hay oportunidad de anotar más puntos (en el horizonte, en este caso, 2 jugadas (profundidad))
 - Por ello, la espera es tan buena como el comer: puede ir east, luego west en la siguiente ronda de planificación


Video Demo Thrashing – Fijado ($d=2$)



El problema no era el minimax sino la función de evaluación


[Demo: thrashing $d=2$, thrashing $d=2$ (fixed evaluation function) (L6D7)]

Funciones de Evaluación



Funciones de Evaluación

- Las funciones de evaluación puntúan no terminales, con búsqueda de profundidad limitada




- Función Ideal: devuelve el valor real de minimax en esa posición
- En la práctica: normalmente suma lineal ponderada de características (features)

$$Eval(s) = w_1 * f_1(s) + w_2 * f_2(s) + \dots + w_n * f_n(s)$$

- Por ejemplo:

$$f_1(s) = (\text{cantidad de reinas blancas} - \text{cantidad reinas negras}), \text{ etc.}$$

Evaluación para Pacman



[Demo: thrashing d=2, thrashing d=2 (fixed evaluation function), smart ghosts coordinate (L6D6,7,8,10)]

Vídeo Demo Fantasma inteligentes (Coordinación)



Vídeo Demo Fantasma inteligentes (Coordinación) – con Zoom



La profundidad importa

- Las funciones de evaluación son siempre imperfectas
- Cuanto más profundamente en el árbol probemos la función de evaluación, es menos importante la calidad de la función de evaluación
- Un ejemplo interesante de compensación (tradeoff) entre complejidad de la función de evaluación y complejidad de cálculo



[Demo: depth limited (L6D4, L6D5)]


Vídeo Demo Profundidad limitada (2)






Vídeo Demo Profundidad limitada (10)



Resultados inciertos




Caso peor vs. caso medio



Idea: los resultados inciertos están controlados por el azar, no por el adversario!

Búsqueda Expectimax

- ¿Por qué podemos no conocer el resultado de una acción?
 - Aleatoriedad explícita: echar los dados
 - Oponentes impredecibles: los fantasmas responden aleatoriamente
 - Las acciones pueden fallar: al mover un robot, las ruedas pueden patinar
- Los valores deberían reflejar resultados medios (expectimax), no resultados en el caso peor (minimax)
- Búsqueda Expectimax: calcular la puntuación media con un juego óptimo
 - Nodos Max como en búsqueda minimax
 - Los nodos aleatorios son como los nodos min pero el resultado es incierto
 - Se calcularán las utilidades esperadas
 - P. ej. Tomar la media ponderada (expectativa) de los hijos



Pseudocódigo de Expectimax

```
def value(state):
```

```
    if the state is a terminal state: return the state's utility
```

```
    if the next agent is MAX: return max-value(state)
```

```
    if the next agent is EXP: return exp-value(state)
```

```
def max-value(state):
```

```
    initialize v =  $-\infty$ 
```

```
    for each successor of state:
```

```
        v = max(v,  
                value(successor))
```

```
    return v
```

```
def exp-value(state):
```

```
    initialize v = 0
```

```
    for each successor of state:
```


```
        p = probability(successor)
```

```
        v += p * value(successor)
```

```
    return v
```


Pseudocódigo de Expectimax

```
def exp-value(state):  
    initialize v = 0  
    for each successor of state:  
        p = probability(successor)  
        v += p * value(successor)  
    return v
```



$$v = (1/2) (8) + (1/3) (24) + (1/6) (-12) = 10$$



Ejemplo de Expectimax



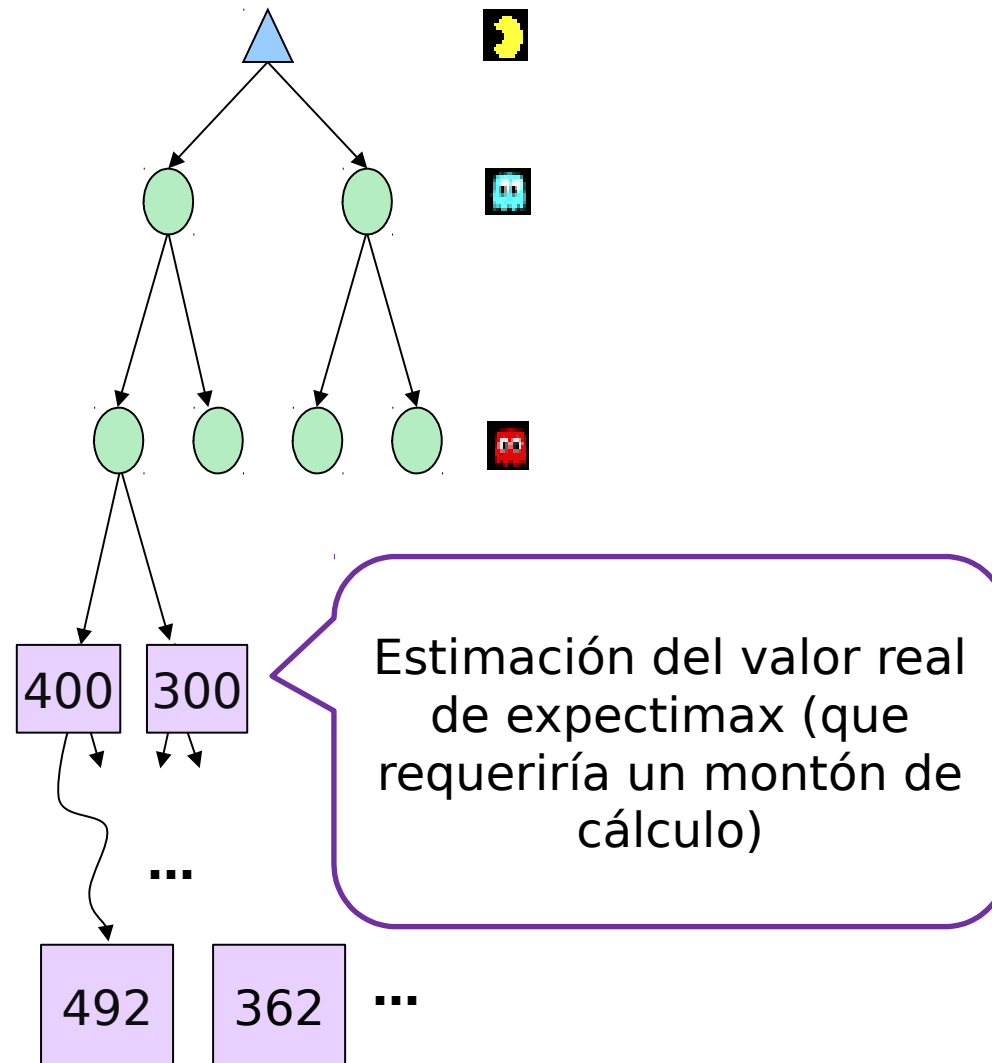
Vídeo Demo Expectimax




¿Poda de Expectimax?



Expectimax con profundidad limitada



Probabilidades



Recuerdo: Probabilidades


- Una **variable aleatoria (random)** representa un evento cuyo resultado es desconocido
- Una **distribución de probabilidad** es una asignación de pesos a resultados

- Ejemplo: Tráfico en la autopista

- Variable aleatoria: T = hay tráfico o no
- Valores: T en {nada, ligero, mucho}
- Distribución: $P(T=\text{nada}) = 0.25$, $P(T=\text{ligero}) = 0.50$, $P(T=\text{mucho}) = 0.25$


- Algunas leyes de probabilidad:

- Las Probabilidades son siempre no negativas
- La suma de Probabilidades sobre todos los valores posibles suma uno






Recuerdo: Expectativas

- El valor esperado de una función de una variable aleatoria es la media, ponderada por la distribución de probabilidad de los resultados
- Ejemplo: ¿Cuánto tardaré en llegar al aeropuerto?




$$\begin{array}{rcccl} \text{Tiempo:} & 20 \text{ min} & & 30 \text{ min} & & 60 \text{ min} \\ & \times & + & \times & + & \times \\ \text{Probabilidad:} & 0.25 & & 0.50 & & 0.25 \end{array} \quad \rightarrow \quad 35 \text{ min}$$



¿Qué probabilidades usamos?


- En la búsqueda expectimax, tenemos un modelo probabilístico de cómo el oponente (o entorno) se comportará en cualquier estado
 - El Modelo podría ser una distribución uniforme (echar los dados)
 - El Modelo podría ser sofisticado y requerir un montón de computación
 - Tendremos un nodo aleatorio por cada situación fuera de nuestro control: oponente o entorno
 - ¡El modelo podría decir qué acciones adversariales son probables!
- Por ahora, asumiremos que cada nodo viene mágicamente con probabilidades que especifican la distribución respecto a sus valores



¡Tener una suposición probabilística sobre la acción de otro agente no quiere decir que ese agente esté echando una moneda!


Quiz: Probabilidades informadas

- Supongamos que nuestro oponente está ejecutando un minimax de profundidad 2, usando ese resultado un 80% de las veces, y moviéndose aleatoriamente en otro caso
- Pregunta: ¿Qué tipo de búsqueda en árbol usaríamos?



- Respuesta: ¡Expectimax!
- Para estimar las probabilidades de CADA nodo aleatorio, tendríamos que ejecutar una simulación de nuestro oponente
- Esto nos puede llevar rápidamente a ineficiencia (tiempo)
- Peor si tenemos que simular a nuestro oponente simulándonos a nosotros ...
- ... excepto para minimax, que tiene la (buena) propiedad de que todo se junta en un árbol de juegos


Modelando Asunciones



Los peligros del optimismo y el pesimismo

Optimismo peligroso

Asumiendo azar cuando el mundo es adversarial




Pesimismo peligroso

Asumiendo el caso peor cuando es poco probable



Asunciones vs. Realidad



	Fantasma Adversarial	Fantasma Aleatorio
Minimax Pacman	Won 5/5 Avg. Score: 483	Won 5/5 Avg. Score: 493
Expecti max Pacman	Won 1/5 Avg. Score: -303	Won 5/5 Avg. Score: 503

Resultados jugando 5 juegos

- Pacman usó búsqueda de profundidad 4 con una función de evaluación que evita problemas
- El fantasma usó búsqueda de profundidad 2 con una función de evaluación que busca a Pacman

[Demos: world assumptions (L7D3,4,5,6)]

Vídeo Demo Asunciones sobre el mundo

Fantasma aleatorio – Pacman Expectimax



Vídeo Demo Asunciones sobre el mundo

Fantasma Adversarial – Pacman Minimax



Vídeo Demo Asunciones sobre el mundo Fantasma Adversarial – Pacman Expectimax




Vídeo Demo Asunciones sobre el mundo

Fantasma aleatorio – Pacman Minimax





Otros tipos de juegos



Tipos de nivel mixtos

- P. ej. Backgammon
- Expectiminimax
 - El entorno es un “agente aleatorio” extra que mueve después de cada agente min/max
 - Cada nodo calcula la combinación apropiada para sus hijos



Ejemplo: Backgammon

- Al echar los dados se incrementa b : 21 resultados posibles con 2 dados
 - Backgammon ~ 20 movimientos legales
 - Profundidad 2 = $20 \times (21 \times 20)^3 = 1.2 \times 10^9$
- Al aumentar la profundidad, la probabilidad de llegar a un nodo disminuye
 - Por ello disminuye la utilidad de la búsqueda
 - Por ello limitar la profundidad es menos dañino
 - Pero el podado es más complicado ...
- AI histórica: TDGammon usa búsqueda de profundidad 2 search + muy buena función de evaluación + reinforcement learning: nivel de juego de campeón mundial
- ¡Primer campeón mundial automático en un juego!



Utilidades Multi-agente

➤ ¿Qué pasa si el juego no es de suma cero, o hay varios jugadores?

➤ Generalización de minimax:

- Los terminales tienen tuplas de utilidades
- Los valores de los nodos son también
- tuplas de utilidades
- Cada jugador maximiza su componente
- Puede dar lugar a competición y
- cooperación dinámicamente

